

Trabajo Práctico 4 - Encoders, decoders y autoencoders

Tecnología Digital VI: Inteligencia Artificial

Federico Giorgi

Gastón Loza Montaña

Tomás Curzio

24/11/23

Encodear canciones en vectores latentes

Para este primer inciso, utilizamos una red sencilla, muy similar a los autoencoders vistos en clase, utilizando la estructura que se puede ver en la figura 1.




Figura 1: Estructura autoencoder

En un principio, pudimos notar que la estrategia de hacer muchos canales en un inicio y luego disminuirlos no nos dió buenos resultados. Por ello, probamos ir disminuyendo de a poco o mantener

los canales a lo largo de la red, para finalmente flattenear el vector y obtener así nuestro vector latente. Realizamos esto con distintos parámetros que nos dejaron vectores latentes de distintos tamaños, hasta llegar al punto de que la canción sea prácticamente irreconocible. Los audios resultantes se pueden ver en la siguiente tabla, que utiliza Music - Maddona como ejemplo.

¿Quizás agregar a la tabla los parámetros? (in/out channels, kernel size, stride, etc)

Vector latente	
1x110250 (Original)	link
1x55112	link
1x32151	link
1x24496	link
1x18376	link
1x9184	link

En cuanto a los otros hiperparámetros, tomamos las siguientes decisiones.

- Decidimos dejar las epochs que venían por defecto en la notebook otorgada, por un tema de tiempo de cómputo, además de que observamos que la loss comenzaba a mantenerse bastante estable y no parecía tener mucha proyección a disminuir en futuras epochs.
- En cuanto al learning rate, corrimos un hyperopt con algunas iteraciones y el resultado obtenido (aprox 0.015) fue muy cercano al learning rate que venía por defecto en la notebook otorgada. Corrimos algunos experimentos con el learning rate obtenido y la diferencia era prácticamente nula, entonces a fines de poder comparar entre los distintos experimentos que ya habíamos realizado, decidimos mantener este parámetro en 0.02.
- No se me ocurre acá como explicar bien porque mantuvimos el batch size como venía.

Para no tener solamente una diferencia de audio como referencia, también observamos como difieren tanto la waveform como el espectograma de la canción original, con los de los distintos audios encodeados y luego decodeados, observados en la tabla. Estos fueron los resultados:

Acá pondría las imagenes de los waveforms y de los espectogramas, primero el del original y despues el de los demás en orden decreciente.

Observando y escuchando, decidimos quedarnos como “vector de mínimo tamaño” el de ¿1x18376? ¿1x24496?, ya que consideramos que mantiene una similitud razonable con el audio original, a diferencia de el vector de 1x9184, que es prácticamente inentendible. Con esto, ya podemos avanzar a un análisis exploratorio de los vectores latentes obtenidos.

Análisis exploratorio de vectores latentes

Para el análisis exploratorio de los vectores latentes procedimos a probar distintos métodos.

En primer lugar, exploramos que resultaba de hacer un clustering con **k-medias**. Para ello, ejecutamos el algoritmo de la librería **sklearn** con valores crecientes de K para evaluar cómo varía la función que mide las distancias a los centroides (within groups sums of squares) para poder observar en cuántos clusters se podría dividir los vectores latentes, con la expectativa que sea una cantidad similar a los géneros a los que pertenecen las canciones. Como se puede ver en la figura 2, aún con k igual a 40 el modelo sigue con una within groups sums of squares muy alta, y no se logra observar ningún “codo” en el gráfico. Por lo tanto, es claro notar que aún con los vectores latentes más chicos (de 9k), son demasiados atributos y por ende muchas dimensiones para que el algoritmo de **k-medias** pueda encontrar una clustering relativamente chico. Por ese motivo, procedemos a analizar otras opciones.

Para no olvidarme:




Figura 2: Within groups sums of squares a medida de aumenta k

- Explicar el decision tree (con las imagenes que se vea que son todos parecidos en una sola imagen, 5 es un monton)
- PCA, explicar que por un motivo similar a k-means no sirve mucho pero del analisis sale que parece que los outliers son iguales en casi todos los vectores latentes lo cual es bueno pq significa que está capatando la misma información a pesar de haber sido encodeados de diferentes maneras.

Encodeo de música nueva

Con la red definida, en un principio no se podría encodear música nueva, a no ser que tanto su sample rate como su tamaño original, sea el mismo que el de los audios del dataset que estamos utilizando para entrenar y validar nuestra red.

Para poder hacerlo, hay algunas opciones:

1. Adaptar el audio que querramos encodear para cumplir los requisitos de la red.
2. Adaptar la red para el sample rate y tamaño original de aquello que querramos encodear.
3. Adaptar el sample rate que viene por defecto al del audio que querramos encodear, y reducir el tamaño del mismo a los requisitos de la red (recortandolo a 5s como los demás).

Tras el siguiente proceso pudimos encodear música nueva.

1. Entrenar la red normalmente, con el dataset otorgado.
2. Nuestro audio era stereo (2 channels) así que lo pasamos a mono con un convertidor online.
3. Una vez convertido a mono, cortamos un fragmento de 5 segundos con el código provisto.
4. Así, el vector era de tamaño 1x1x220500, que no cumple con las características que necesita la red (1x1x110250). Para solventarlo, utilizamos la función de Resampling de PyTorch, obteniendo así un vector con las características necesarias.
5. Realizamos un forward en la red con nuestro vector de audio nuevo una vez que cumplía las características necesarias.
6. Obtuvimos el audio reconstruido, así como su espectograma y waveform.
7. Repetimos el proceso para distintos tamaños de vectores latentes y obtuvimos los que se pueden ver en la siguiente tabla.

No tuvimos problemas con el sample rate, pero podría haber llegado a tener que editarse, pues este se encuentra hardcoded en 22050. En nuestro caso funcionó correctamente sin cambiarlo, ya que al hacer el re-sampling paso de 44100 a 20500.

¿Quizás agregar a la tabla los parámetros? (in/out channels, kernel size, stride, etc)

Vector latente	
1x110250 (Original)	link
1x55112	link
1x32151	link
1x24496	link
1x18376	link
1x9184	link

Generación de música nueva.

Hemos visto en clase como este tipo de autoencoders que hemos programado, no son lo mejor para generar algo nuevo. Es por eso, que han surgido otros modelos, como pueden ser VAE o GAN. Sin

embargo, se pueden probar cosas como generar vectores random del tamaño del espacio latente y pasarlos por el decoder o incluso promediar vectores latentes de otras canciones y decodearlos.

Este tipo de cosas son las que probamos hacer y, si bien lo obtenido no es lo mas satisfactorio, logramos generar audio completamente nuevo a partir de nuestra red. Se pueden escuchar los audios obtenidos en la siguiente tabla:

Vector latente	
1x110250 (Original)	link
1x55112	link
1x32151	link
1x24496	link
1x18376	link
1x9184	link

(copie siempre la misma tabla por las dudas, me parece una buena manera de mostrar los resultados pero lo podemos cambiar si se nos ocurre algo mejor)